

# memo de probabilités et de statistiques

Simon Querie

2022-2023

## 1 Tribu, $\pi$ -système, $\lambda$ -système

Une **tribu**  $\mathcal{F}$  sur un ensemble  $\Omega$  est une famille de parties de  $\Omega$  qui contient  $\Omega$ , stable par passage au complémentaire et stable par union dénombrable.

Un  **$\pi$ -système**  $\mathcal{C}$  sur un ensemble  $\Omega$  est un ensemble de parties de  $\Omega$  non vide et stable par intersection finie.

Un  **$\lambda$ -système**  $\Lambda$  sur un ensemble  $\Omega$  est un ensemble de parties de  $\Omega$  stables par passage au complémentaire et par union dénombrable de suites d'éléments deux à deux disjoints de  $\Lambda$ .

**Théorème de classe monotone** Si  $\mathcal{C} \subseteq \Lambda$  alors  $\sigma(\mathcal{C}) \subseteq \Lambda$

## 2 Espérance, Variance, Covariance

Soit  $X$  une v.a à valeurs complexes. Quand elle existe on définit son espérance par  $\mathbb{E}(X) = \int_{\Omega} X d\mathbb{P}$

**Théorème de transfert**  $\int_{\Omega} f \circ X d\mathbb{P} = \int_{\mathbb{X}} f dP^X$

$\text{Cov}(X) = \mathbb{E}((X - \mathbb{E}(X))(X - \mathbb{E}(X))^H)$  (pour le cas où  $X$  est complexe/réelle il s'agit de la variance de  $X$ )

$\text{Cov}(X, Y) = \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y))^H)$

$\mathbb{E}(AX + b) = A\mathbb{E}(X) + b$ ,  $\text{Cov}(AX + b) = A\text{Cov}(X)A^H$

**Inégalité de Markov**  $\mathbb{P}(|X| \geq a) \leq \frac{\mathbb{E}(|X|)}{a}$

Soit  $X, Y$  deux variables aléatoires réelles.

**Inégalité de Cauchy-Schwartz**  $\mathbb{E}(|XY|) \leq$

$$\mathbb{E}(X^2)^{1/2} \mathbb{E}(Y^2)^{1/2}$$

**Inégalité de Hölder**  $\mathbb{E}(|XY|) \leq \mathbb{E}(|X|^p)^{1/p} \mathbb{E}(|Y|^q)^{1/q}$   
pour  $\frac{1}{p} + \frac{1}{q} = 1$

**Inégalité de Jensen** Si  $\phi$  est convexe et que  $\phi(X)$  est  $L^1$  alors  $\phi(\mathbb{E}(X)) \leq \mathbb{E}(\phi(X))$

## 3 Espérance conditionnelle

Soit  $\mathcal{G} \subseteq \mathcal{F}$  une sous tribu. Si  $X$  est  $L^1$ , il existe une unique variable aléatoire  $Y$  dans  $L^1(\Omega, \mathcal{G}, \mathbb{P})$  tq  $\forall A \in \mathcal{G}$   $\mathbb{E}(\mathbb{1}_A Y) = \mathbb{E}(\mathbb{1}_A X)$  On note cette v.a  $\mathbb{E}(X|\mathcal{G})$

Dans le cas où  $X$  est  $L^2$  on a  $\mathbb{E}(X|\mathcal{G}) = \text{proj}(X|L^2(\Omega, \mathcal{G}, \mathbb{P}))$

### Propriétés

L'espérance conditionnelle est linéaire et positive. Si  $X$  est  $\mathcal{G}$  mesurable  $\mathbb{E}(X|\mathcal{G}) = X$ . Si  $X \perp \mathcal{G}$  ou si  $\mathcal{G} = \{\Omega, \emptyset\}$   $\mathbb{E}(X|\mathcal{G}) = \mathbb{E}(X)$ .

$$(i) \mathbb{E}(|\mathbb{E}(X|\mathcal{G})|) \leq \mathbb{E}(|X|)$$

$$(ii) \mathbb{E}(X|\mathcal{G}) \vee \mathbb{E}(Y|\mathcal{G}) \leq \mathbb{E}(X \vee Y|\mathcal{G})$$

$$(iii) \mathbb{E}(X|\mathcal{G})_+ \leq \mathbb{E}(X_+|\mathcal{G})$$

$$(iv) |\mathbb{E}(X|\mathcal{G})| \leq \mathbb{E}(|X||\mathcal{G})$$

$$(v) \text{ (Tower property) Si } \mathcal{G} \subseteq \mathcal{H} \text{ alors } \mathbb{E}(\mathbb{E}(X|\mathcal{H})|\mathcal{G}) = \mathbb{E}(X|\mathcal{G})$$

$$(vi) \mathbb{E}(\mathbb{E}(X|\mathcal{G})) = \mathbb{E}(X)$$

$$(vii) \text{ Si } X \text{ est } \mathcal{G} \text{ mesurable et } XY \text{ est } L^1 \text{ alors : } \mathbb{E}(XY|\mathcal{G}) = X \mathbb{E}(Y|\mathcal{G})$$

$$(viii) \text{ Si } \phi \text{ est une fonction convexe et si } \phi(X) \text{ est } L^1 \text{ alors } \phi(\mathbb{E}(X|\mathcal{G})) \leq \mathbb{E}(\phi(X)|\mathcal{G})$$

## 4 Noyau et loi conditionnelle

Soit  $(E_1, \mathcal{E}_1), (E_2, \mathcal{E}_2)$  deux espaces mesurables. Un noyau est une application  $N : E_2 \times \mathcal{E}_1 \rightarrow [0, +\infty]$  tel que : (i)  $\forall x \in E_2$   $N(x, \cdot)$  est une mesure et (ii)  $\forall A \in \mathcal{E}_1$   $N(\cdot, A)$  est mesurable.

De plus,  $N$  est un noyau de probabilité si  $\forall x \in E_2$   $N(x, \cdot)$  est une mesure de probabilité.

Loi sachant  $\mathcal{G}$   $\mathbb{P}^{\mathcal{G}}$  : noyau de probabilité  $\Omega \times \mathcal{F}$  tel que  $\mathbb{P}^{\mathcal{G}}(\cdot, A) = \mathbb{E}(\mathbb{1}_A | \mathcal{G})$

Loi de  $X$  sachant  $\mathcal{G}$   $\mathbb{P}^{X|\mathcal{G}}$  : noyau de probabilité  $\Omega \times \mathcal{X}$  tel que  $\mathbb{P}^{X|\mathcal{G}}(\cdot, A) = \mathbb{E}(\mathbb{1}_A(X) | \mathcal{G})$

Loi de  $X$  sachant  $Y$   $\mathbb{P}^{X|Y}$  : noyau de probabilité  $Y \times \mathcal{X}$  tel que  $\mathbb{P}^{X|Y}(Y, A) = \mathbb{E}(\mathbb{1}_A(X) | Y)$

On définit la densité conditionnelle de  $X$  sachant  $Y$  par  $f^{X|Y}(x|y) = \frac{f^{(X,Y)}(x,y)}{f^Y(y)}$

Soit  $N$  un noyau sur  $\mathbf{X} \times \mathcal{Y}$  et  $\mu \in \mathbb{M}_+(\mathbf{X}, \mathcal{X})$  on peut définir la mesure  $\mu \otimes N$  sur  $\mathcal{X} \otimes \mathcal{Y}$  par  $\mu \otimes N(C) = \int \left( \int \mathbb{1}_C(x, y) N(x, dy) \right) \mu(dx)$

**Théorème de désintégration** Soient  $X$  et  $Y$  deux variables aléatoires de  $(\Omega, \mathcal{F}, \mathbb{P})$  dans  $\mathbf{X}$  et  $\mathbf{Y}$  respectivement. Si  $\mathbb{P}^{(X,Y)} = \mu \otimes N$  alors  $\mu = \mathbb{P}^X$  et  $\mathbb{P}^{Y|X} = N$

## 5 Difféomorphisme et changement de variable

Soit  $\phi : U \rightarrow V$  un difféomorphisme. On note  $J_\phi = \left( \frac{\partial \phi_i}{\partial x_j} \right)_{1 \leq i, j \leq n}$  le jacobien de  $\phi$ . On a  $\int_U f = \int_V \frac{f \circ \phi^{-1}}{|\det J_\phi \circ \phi^{-1}|}$

Si  $Y = \phi(X)$  alors  $f_Y = \frac{f_X \circ \phi^{-1}}{|\det J_\phi \circ \phi^{-1}|} \mathbb{1}_V$

## 6 Lois usuelles

### 6.1 Lois discrètes

Nom	Mesure de probabilité $\mu$	Fonction caractéristique	$m$	$\sigma^2$
Loi de Bernoulli $\mathcal{B}(p)$	$p\delta_0 + q\delta_1$	$pe^{it} + q$	$p$	$pq$
Loi Binomiale $\mathcal{B}(n, p)$	$\sum_{k=0}^n \binom{n}{k} p^k q^{n-k} \delta_k$	$(pe^{it} + q)^n$	$np$	$npq$
Loi de Poisson $\mathcal{P}(\lambda)$	$\sum_{k=0}^{+\infty} \frac{\lambda^k e^{-\lambda}}{k!} \delta_k$	$\exp(\lambda(e^{it} - 1))$	$\lambda$	$\lambda$
Loi géométrique $\mathcal{G}(p)$ sur $\mathbb{N}$	$\sum_{n=0}^{+\infty} pq^n \delta_n$	$\frac{p}{1 - qe^{it}}$	$\frac{q}{p}$	$\frac{q}{p^2}$
Loi géométrique $\mathcal{G}(p)$ sur $\mathbb{N}^*$	$\sum_{n=1}^{+\infty} pq^{n-1} \delta_n$	$\frac{pe^{it}}{1 - qe^{it}}$	$\frac{1}{p}$	$\frac{q}{p^2}$

## 6.2 Lois à densité par rapport à la mesure de Lebesgue

Nom	Densité	Fonction caractéristique	$m$	$\sigma^2$
Loi uniforme $\mathcal{U}([a, b])$	$\frac{1}{b-a} \mathbb{1}_{[a, b]}$	$\frac{e^{itb} - e^{ita}}{it(b-a)}$	$\frac{b-a}{2}$	$\frac{(b-a)^2}{12}$
Loi de Cauchy	$\frac{1}{\pi} \frac{1}{1+x^2}$	$e^{- t }$	n'existe pas	n'existe pas
Loi normale $\mathcal{N}(m, \sigma^2)$	$\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-m)^2}{2\sigma^2}}$	$e^{itm - \frac{t^2\sigma^2}{2}}$	$m$	$\sigma^2$
Loi exponentielle $\mathcal{E}(\lambda)$	$\mathbb{1}_{\mathbb{R}_+}(x) \lambda e^{-\lambda x}$	$\left(1 - \frac{it}{\lambda}\right)^{-1}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
Loi Gamma $\Gamma(a, b)$	$\mathbb{1}_{\mathbb{R}_+}(x) \frac{b^a}{\Gamma(a)} e^{-bx} x^{a-1}$	$\left(1 - \frac{it}{b}\right)^{-a}$	$\frac{a}{b}$	$\frac{a}{b^2}$
Loi du chi-deux à $n$ degrés de liberté $\chi_n^2$	$\mathbb{1}_{\mathbb{R}_+}(x) \frac{e^{-\frac{x}{2}} x^{\frac{n}{2}-1}}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})}$	$(1 - 2it)^{-\frac{n}{2}}$	$n$	$2n$

## 7 Vecteurs gaussiens

**Définition :**  $X = (X_1, \dots, X_d)$  est un vecteur gaussien si pour tout  $t \in \mathbb{R}^d$   $\langle t, X \rangle$  suit une loi normale.

Si  $X \sim \mathcal{N}(m, \Gamma)$  alors  $\phi_X(t) = \mathbb{E}(e^{i\langle t, X \rangle}) = e^{i\langle t, m \rangle - \frac{1}{2} t^T \Gamma t}$  et si  $\Gamma \in GL_n(\mathbb{R})$  alors :

$$f_X(x_1, \dots, x_d) = \frac{1}{\sqrt{(2\pi)^d |\det \Gamma|}} \exp\left(-\frac{1}{2} \langle \Gamma^{-1}(x - m), x - m \rangle\right)$$

Soient  $(X_1, \dots, X_n)$   $n$  variables aléatoires. Les deux assertions sont équivalentes :

- (i)  $X_1, \dots, X_n$  sont  $n$  variables gaussiennes indépendantes
- (ii)  $(X_1, \dots, X_n)$  est un vecteur gaussien dont la matrice de covariance est diagonale

Autrement dit, pour un vecteur gaussien, la décorrélation implique l'indépendance.

## 8 Statistiques

Un **modèle statistique** est une famille de mesures de probabilité. Une **statistique**  $S$  est une fonction mesurable des observations. Un **estimateur** est une statistique qui cherche à estimer un paramètre.

On considère des modèles **dominés** i.e tels qu'il existe une mesure  $\mu$  telle que pour toute probabilité  $P$  du modèle  $P$  admette une densité par rapport à  $\mu$ . Les modèles considérés sont également **paramétrisés** i.e qu'il existe une bijection  $\theta \in \Theta \mapsto P_\theta \in \mathcal{P}$ .

L'**erreur quadratique moyenne** est :

$$EQM(\hat{g}, \theta) := \mathbb{E}_\theta((\hat{g}(X) - g(\theta))^2) = \mathbb{E}_\theta(\hat{g}(X) - g(\theta))^2 + V_\theta(\hat{g}(X)) = b(\hat{g}, \theta)^2 + V_\theta(\hat{g}(X)) = \text{biais}^2 + \text{variance}$$

Une **statistique suffisante** est une statistique  $S$  telle que pour toute probabilité du modèle  $P \in \mathcal{P}$  la loi de  $X|S$  ne dépend pas de  $P$ .

**Théorème de factorisation de Fisher :** Si  $S = g(X)$  et que  $\forall \theta \in \Theta \ p_\theta = h \times f_\theta \circ g$  alors  $S$  est une statistique suffisante.

## 9 Intuitions

Une statistique suffisante est une fonction des observations qui conserve l'information nécessaire à la détermination du paramètre  $\theta$ . En théorie de l'information :  $I(X, \theta) = I(g(X), \theta)$ .

Une loi conditionnelle est une probabilité paramétrée. C'est une loi de probabilité qui est elle-même "aléatoire". La notation  $K(x, A)$  correspond à l'intuition  $Y \in A$  sachant  $X = x$ .

## 10 Chaînes de Markov

**Définition** Une chaîne de Markov est un processus filtré  $(X_n, \mathcal{F}_n)_{n \in \mathbb{N}}$  tel que :

$$\forall A \in \mathcal{F} \quad \mathbb{P}(X_{n+1} \in A \mid \mathcal{F}_n) = \mathbb{P}(X_{n+1} \in A \mid X_n)$$

Une chaîne de Markov est caractérisée par sa loi initiale  $\nu$  et ses noyaux de transition  $(P_k)_{k \in \mathbb{N}}$ . Une chaîne de Markov est **homogène** s'il existe un noyau  $P$  tel que pour tout  $k \in \mathbb{N}$  et tout  $A \in \mathcal{X}$  on ait  $\mathbb{P}(X_{k+1} \in A \mid X_k) = P(X_k, A)$ . La loi de  $X_k$  est alors  $\nu P^k$ .

## 11 Martingales à temps discret

Soit  $(\Omega, \mathcal{F}, (\mathcal{F}_n)_n, \mathbb{P})$  un espace de probabilité filtré.

**Définition** Un processus  $L^1$  adapté  $(X_n)_{n \in \mathbb{N}}$  est une martingale si  $\forall n \in \mathbb{N} \quad \mathbb{E}(X_{n+1} \mid \mathcal{F}_n) = X_n$ .

**Exemple 1 (Marche aléatoire)** Soit  $(X_k)_k$  une suite de variables intégrables, indépendantes de moyenne nulle. Alors le processus  $(S_n)_n$  défini par  $S_0 = 0$  et  $S_n = \sum_{k=1}^n X_k$  est une martingale (pour la filtration  $\mathcal{F}_0 = \{\emptyset, \Omega\}$  et  $\mathcal{F}_n = \sigma(X_1, \dots, X_n)$ )

**Exemple 2 (Martingale produit)** Soit  $(X_k)_k$  une suite de variables intégrables, positive de moyenne égale à 1. Alors le processus  $(M_n)_n$  défini par  $M_n = \prod_{k=0}^n X_k$  est une martingale (pour la filtration  $\mathcal{F}_n = \sigma(X_0, \dots, X_n)$ )

**Exemple 3 (Accumulation d'informations sur une variable aléatoire au cours du temps)** Soit  $Y$  une variable aléatoire  $L^1$ . Alors  $(\mathbb{E}(Y \mid \mathcal{F}_n), \mathcal{F}_n)_{n \in \mathbb{N}}$  est une martingale.

**Exemple 4 (Processus de branchement)**

Soit  $(\xi_{i,j})_{(i,j) \in \mathbb{N}^2}$  des variables i.i.d à valeurs dans  $\mathbb{N}$  de moyenne  $m$ . On pose  $\mathcal{F}_0 = \{\emptyset, \Omega\}$  et  $\mathcal{F}_n = \sigma(\xi_{i,j} \mid \forall i \leq n-1)$ .

On définit par récurrence le processus  $(X_n)_n$  par  $X_{n+1} = \sum_{j=1}^{X_n} \xi_{n,j}$ . Le processus  $Z_n = \frac{X_n}{m^n}$  est une martingale.

**Exemple 5 (Statistique de test pour le Sequential Probability Ratio Test)**

**Proposition** Si  $(X_n)_n$  est une martingale alors  $\mathbb{E}(X_n \mid \mathcal{F}_m) = X_m \quad \forall m \leq n$

**Définition** Un processus  $(A_n)_n$  est  $(\mathcal{F}_n)_n$  prévisible si  $\forall n \in \mathbb{N}^* \quad A_n$  est  $\mathcal{F}_{n-1}$  mesurable.

**Proposition** Si  $X$  est une martingale et  $A$  un processus prévisible bornée presque sûrement (i.e pour tout  $n$ ,  $A_n$  est borné presque sûrement) alors  $(A \cdot X)$  est une martingale. Si  $A \geq 0$  presque sûrement et que  $X$  est une sur/sous martingale alors  $(A \cdot X)$  est une sur/sous-martingale.

**Corollaire**

Si  $(X_n)_n$  est une martingale alors pour tout temps d'arrêt  $\tau$ ,  $(X_{n \wedge \tau})_n$  est une martingale.

**Interprétations des martingales en terme de jeu de hasard**

(i)  $X_n - X_{n-1}$

(ii)  $C_n$  (mise au temps  $n$ )

(iii)  $Y_n = (C \cdot X)_n = \sum_{k=1}^n C_k(X_k - X_{k-1})$  (gain total à l'instant  $n$ )

**Stratégie**

$C_1 = \mathbb{1}_{\{X_1 < a\}}$  et  $C_n = \mathbb{1}_{\{C_{n-1}=1\}} \mathbb{1}_{\{X_1 \leq b\}} + \mathbb{1}_{\{C_{n-1}=0\}} \mathbb{1}_{\{X_1 < a\}}$

**Doob's Upcrossing Lemma**

Soit  $a < b$ .

Si  $(X_n)$  est une sous-martingale alors  $(b-a)\mathbb{E}(U_n^X(a,b)) \leq \mathbb{E}((X_n-a)_+) - \mathbb{E}((X_0-a)_+)$

Si  $(X_n)$  est une sur-martingale alors  $(b-a)\mathbb{E}(U_n^X(a,b)) \leq \mathbb{E}((X_n-a)_-)$

### **Théorème d'arrêt**

Soit  $\underline{\nu} \leq \bar{\nu}$  deux temps d'arrêt bornés presque sûrement. Alors  $\mathbb{E}(X_{\bar{\nu}} | \mathcal{F}_{\underline{\nu}}) = X_{\underline{\nu}}$

**Corollaire**  $(X_n)_n$  est une martingale si et seulement si pour tout temps d'arrêt  $L^\infty \tau$  on a  $\mathbb{E}(X_\tau) = \mathbb{E}(X_0)$

**Identité de Wald** Soit  $\sigma$  un temps d'arrêt  $L^1$  et  $S_n = \sum_{k=1}^n X_k$  une marche aléatoire. Alors  $\mathbb{E}(S_\sigma) = \mathbb{E}(\sigma)\mathbb{E}(X_1)$

### **Inégalités maximales**

On pose  $X_n^* = \max(X_0, X_1, \dots, X_n)$ .

(i) Si  $X$  est une sous-martingale, alors pour tout  $a \geq 0$  et pour tout  $n \in \mathbb{N}$  on a  $a\mathbb{P}(X_n^* \geq a) \leq \mathbb{E}(X_n \mathbb{1}_{\{X_n^* \geq a\}})$

(ii) Si  $X$  est une sous-martingale positive, alors pour tout  $a \geq 0$  et  $n \in \mathbb{N}$  :  $a\mathbb{P}(X_n^* \geq a) \leq \mathbb{E}(X_n)$ .

(iii) Si  $X$  est une sur-martingale positive alors pour tout  $a \geq 0$  on a :  $a\mathbb{P}(\sup X_n^* \geq a) \leq \mathbb{E}(X_0)$

(iv) (Maximal Doob inequality) Si  $|X|$  est une sous-martingale alors pour tout  $n \in \mathbb{N}$  et  $p > 1$  :  $\|X|_n^*\|_p \leq \frac{p}{p-1} \|X_n\|_p$

### **Théorème de décomposition de Doob**

Tout processus  $L^1$   $(X_n, \mathcal{F}_n)_{n \in \mathbb{N}}$  se décompose comme la somme d'une martingale et d'un processus prévisible :  $X_n = M_n + A_n$  et  $A_n = A_{n-1} + \mathbb{E}(\Delta X_n | \mathcal{F}_{n-1})$  i.e  $\Delta A_n = \mathbb{E}(\Delta X_n | \mathcal{F}_{n-1})$

## **Théorèmes de convergence**

### **Martingale bornée dans $L^1$**

Soit  $(X_n)_n$  une suite de v.a  $L^1$ . On dit que  $(X_n)_n$  est bornée dans  $L^1$  si  $\sup_{n \in \mathbb{N}} \mathbb{E}(\|X_n\|) < +\infty$ .

Une martingale/sur-martingale ou sous-martingale bornée dans  $L^1$  converge dans  $L^1$  et presque sûrement et la limite est la même.

### **Martingale bornée dans $L^2$**

Soit  $(X_n)_n$  une suite de v.a  $L^2$ . On dit que  $(X_n)_n$  est bornée dans  $L^2$  si  $\sup_{n \in \mathbb{N}} \mathbb{E}(\|X_n\|^2) < +\infty$ .

Une martingale/sur-martingale ou sous-martingale bornée dans  $L^2$  converge dans  $L^2, L^1$ , presque sûrement et la limite est la même.

## Uniforme Intégrabilité (U.I)

**Définition** Une famille  $(X_t)_{t \in T}$  de variables aléatoires est dite uniformément intégrable si

$$\lim_{c \rightarrow +\infty} \sup_{t \in T} \mathbb{E}(|X_t| \mathbb{1}_{\{|X_t| \geq c\}}) = 0$$

Une famille de v.a uniformément intégrable est bornée dans  $L^1$ .

### Théorème

#### Loi 0-1 de Kolmogorov

Soit  $(X_n)_n$  une suite de variables aléatoires indépendantes. On pose  $\mathcal{T}_\infty := \bigcap_{n \in \mathbb{N}} \sigma(X_{n+k}, k \geq 0)$  la tribu asymptotique.

Pour tout  $A \in \mathcal{T}_\infty$  on a  $\mathbb{P}(A) = 0$  ou  $\mathbb{P}(A) = 1$ .

#### Lois des grands nombres

Soit  $(X_n)_{n \in \mathbb{N}^*}$  une suite de variables aléatoires  $L^1$  i.i.d. Alors  $\frac{1}{n} \sum_{k=1}^n X_k \longrightarrow \mathbb{E}(X_1)$   $\mathbb{P}$  presque partout.

## 12 Convergence des variables aléatoires

### Lemme de Borel-Cantelli

Soit  $(A_n)_n \in \mathcal{F}^{\mathbb{N}}$ . Si  $\sum \mathbb{P}(A_n) < +\infty$  alors  $\mathbb{P}(\limsup A_n) = 0$

Soit  $(A_n)_n \in \mathcal{F}^{\mathbb{N}}$  des évènements **INDÉPENDANTS**. Si  $\sum \mathbb{P}(A_n) = +\infty$  alors  $\mathbb{P}(\limsup A_n) = 1$ .

### Convergence en probabilité

#### Définition

Une suite  $(X_n)_n$  de variables aléatoires converge en probabilité vers  $X$  si  $\forall \varepsilon > 0$  la suite  $\mathbb{P}(\|X_n - X\| > \varepsilon)$  converge vers 0.

#### Lemme

Si  $\forall \varepsilon > 0, \sum \mathbb{P}(\|X_n - X\| > \varepsilon) < +\infty$  alors  $X_n$  converge presque sûrement vers  $X$ .

### Proposition

Une suite  $(X_n)$  converge en probabilité vers  $X$  si et seulement si il existe une extractrice  $(n_k)_k$  telle que  $X_{n_k}$  converge vers  $X$  presque sûrement.

### Proposition

Soit  $(X_n)_n, X : \Omega \rightarrow \mathcal{X}$  des variables aléatoires et  $f : \mathcal{X} \rightarrow \mathcal{Y}$  une fonction continue.

- (i) Si  $X_n \rightarrow X$  p.s alors  $f(X_n) \rightarrow f(X)$  presque sûrement.
- (ii) Si  $X_n \rightarrow X$  en probabilité alors  $f(X_n) \rightarrow f(X)$  en probabilité.

## Convergence en loi

### Définition

Une suite de mesure  $(\mu_n)_n$  sur  $\mathbb{R}^d$  converge étroitement vers une mesure  $\mu$  si pour toute fonction  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  continue et bornée on a  $\mu_n(f) \rightarrow \mu(f)$ .

Une suite de variables aléatoires  $(X_n)_n$  converge en loi vers une variable  $X$  si  $P_{X_n}$  converge étroitement vers  $P_X$ .

### Théorème

La convergence en probabilité implique la convergence en loi.

### Tension

**Définition** Soit  $(\mu_n)_n$  une famille de mesures de probabilité. On dit que cette suite est tendue si pour tout  $\varepsilon > 0$  il existe un compact  $K$  tel que pour tout entier  $n$   $\mu_n(K) \geq 1 - \varepsilon$ . Cela signifie que toute la masse des mesures de probabilité est localisée dans ce compact à  $\varepsilon$  près.

### Théorème de Portmanteau

Les assertions suivantes sont équivalentes.

- (i)  $\mu_n \rightarrow \mu$ .
- (ii) Pour toute fonction  $f$  continue bornée,  $\mu_n(f) \rightarrow \mu(f)$ .
- (iii) Pour toute fonction  $f$  lipschitzienne, continue, bornée  $\mu_n(f) \rightarrow \mu(f)$ .
- (iv) Pour tout  $A \in \mathcal{B}(\mathcal{X})$  tel que  $\mu(\partial A) = 0$ ,  $\mu_n(A) \rightarrow \mu(A)$ .

### Théorème de Portmanteau pour les variables aléatoires

- (i)  $X_n \xrightarrow{\mathcal{L}} X$ .



- (ii) Pour toute fonction  $f$  continue bornée,  $\mathbb{E}(f(X_n)) \longrightarrow \mathbb{E}(f(X))$ .
- (iii) Pour toute fonction  $f$  lipschitzienne, continue, bornée  $\mathbb{E}(f(X_n)) \longrightarrow \mathbb{E}(f(X))$ .
- (iv) Pour tout  $A \in \mathcal{B}(\mathcal{X})$  tel que  $\mathbb{P}(X \in \partial A) = 0$ ,  $\mathbb{P}(X_n \in A) \longrightarrow \mathbb{P}(X \in A)$ .
- (v) Pour tout  $x$ , point de continuité de  $F_X$  on a  $F_{X_n}(x) \longrightarrow F_X(x)$ .

### **Théorème de Prokhorov**

Soit  $(\mu_n)_n$  une suite tendue de mesures de probabilités. Il existe une extraction de cette suite qui converge étroitement vers une mesure  $\mu$ .

### **Théorème de représentation de Skorokhod**

Soient  $(X_n)_n$  des variables aléatoires convergeant en loi vers  $X$ . Il existe un espace  $(E, \mathcal{E}, \mathbb{P})$  et des variables  $(Y_n)_n, Y : E \rightarrow \mathcal{X}$  telles que  $Y_n$  et  $X_n$  ont même loi,  $Y$  et  $X$  ont même loi et  $Y_n$  converge presque sûrement vers  $Y$ .

### **Théorème de Lévy**

Soit  $(\mu_n)_n$  une suite de mesures sur  $\mathbb{R}^d$ . Alors  $(\mu_n)_n$  converge étroitement vers  $\mu$  si et seulement si pour tout  $t \in \mathbb{R}^d$ ,  $\phi_{\mu_n}(t) \longrightarrow \phi_{\mu}(t)$ .

## **Références**

- [1] Probabilités avancées Cours de Master Avancé 1, ENS Lyon de Christophe Garban
- [2] L'essentiel en théorie des probabilités de Jean Jacod et Philip Protter
- [3] Probability with martingales by David Williams
- [4] Polycopié du cours de Probabilités de M1 de François Roueff, Télécom Paris